

Méthodes d'optimisation

Thierry BAY - Philippe Delattre

Ressource R4.04

March 24, 2023

Introduction

- Problème d'optimisation = réduire un coût, maximiser un profit.
- Terme mathématique = min/max. d'une **fonction objectif**.
- Cette fonction :
 - Comporte des **paramètres** ;
 - Est généralement soumise à des **contraintes**.
- Grande variabilité de problèmes, au niveau :
 - Du domaine d'étude : continu, discret ;
 - Du nombre de variables ;
 - Du type de contraintes.
- "Data analysis" vs "business decisions".

Exemples de problèmes

- ❶ **Emploi du temps** - Une université doit effectuer un certain nombre de cours à un certain nombre d'élèves, avec un certain nombre d'enseignants-chercheurs. Contraintes de précédences de cours, salles, désidératas.
Objectif: trouver un planning cohérent.
- ❷ **Flux de transport** - Une coopérative effectue quotidiennement le ramassage de lait.
Objectif: effectuer la tournée la plus courte.
- ❸ **Conception de pièces** - Une entreprise ferroviaire renouvelle son parc pour être plus éco-responsable.
Objectif: concevoir une nouvelle forme de wagon pour réduire l'impact de la prise au vent.

D'importantes considérations

Classification

- Change d'un auteur à l'autre...
- Continuité, linéarité, bornes de la fonction de coût ?
- Variables discrètes ? Continues ?
- Mono-objectif ? Multi-objectifs ?
- Pas de contraintes ? Contraintes linéaires/quadratiques/autres ?
- Connaissances stochastiques ?
- Gradient ? Sans gradient ?

Ces caractéristiques influent sur


- La modélisation : puissance expressive nécessaire.
- Les techniques de résolution.
- La difficulté : efficacité des méthodes/algorithmes.

Méthodes de résolution

Nous verrons deux approches parmi "beaucoup" :

- ① Approche pour l'optimisation convexe :
 - Pourquoi ? Minimum locale = minimum global.
 - Un exemple : la "programmation linéaire".
- ② Approche à base de gradients :
 - Pourquoi ? Permet d'améliorer rapidement la solution lorsque l'on peut calculer la "dérivée".
 - Un exemple : la descente de gradient.
- ③ Méthodes efficaces, qui présentent des limitations. Donc si on applique bêtement un algorithme, il faut s'attendre à ce que ça rate !

Modélisation et choix de la méthode



Une approche en quatre étapes

- ➊ Analyse du problème.
- ➋ Modélisation et choix de méthode.
- ➌ Résolution.
- ➍ Interprétation des résultats.

Programmation linéaire et simplexe

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente

- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal

Vocabulaire de base

Problème 1 - Maximisation

Pour une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ donnée, et un ensemble $M \subseteq \mathbb{R}^n$, trouver $\hat{x} \in M$ qui maximise f sur M tel que : $f(\hat{x}) \geq f(x)$, $\forall x \in M$.

Terminologie :

- f : **fonction-objectif**.
- M : **espace admissible**.
- \hat{x} : **maximiseur de f sur M** .
- Tout $x \in M$ est **solution réalisable ou admissible**.
- $\{x_i\}_{i=1}^n$: **variables d'optimisation ou de décision**.

Inéquations linéaires

Définition 1 - Inéquation linéaire

Une inéquation linéaire est une expression de la forme :

$$a_1x_1 + a_2x_2 + \dots + a_nx_n \leq b,$$

avec x_i les variables, a_i les coefficients des variables, b une constante et n le nombre d'inconnues.

Définition 2 - Solution d'une inéquation linéaire

Solution de l'inéquation linéaire $a_1x_1 + a_2x_2 + \dots + a_nx_n \leq b$: tout n -uplet (y_1, \dots, y_n) tel que l'inégalité $a_1y_1 + a_2y_2 + \dots + a_ny_n \leq b$ est vraie.

Inéquations linéaires

Définition 3 - Système d'inéquations linéaires

On appelle système de m inéquations linéaires à n inconnues un système de la forme :

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \dots + a_{1n}x_n \leq b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \dots + a_{2n}x_n \leq b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + \dots + a_{3n}x_n \leq b_3 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + a_{m3}x_3 + \dots + a_{mn}x_n \leq b_m. \end{cases}$$

où x_j est une variable dans la colonne j , a_{ij} est le coefficient de la variable x_j sur la ligne i , b_i est la constante de la ligne i , n est le nombre d'inconnues et m est le nombre d'inéquations.

De l'algèbre au programme linéaire

Définition 4 - Fonction linéaire

Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est linéaire si et seulement si $f(x + y) = f(x) + f(y)$ et $f(\lambda x) = \lambda f(x)$, avec $x, y \in \mathbb{R}^n$ et $\lambda \in \mathbb{R}$.

Exemple de fonctions linéaires :

- $f_1(x) = x$,
- $f_2(x) = 3x_1 - 5x_2$,
- $f_3(x) = Ax$.

Exemple de fonctions non-linéaires :

- $f_4(x) = x + 1$,
- $f_5(x) = x^2$,
- $f_6(x) = \sin(x)$.

De l'algèbre au programme linéaire

Remarque 1

Toute fonction linéaire $f : \mathbb{R}^n \rightarrow \mathbb{R}$ peut s'exprimer dans la forme $f(x) = Ax$, avec $A \in \mathbb{R}^{m \times n}$ une matrice.

Fournissons quelques détails maintenant sur les notations :

- $x \in \mathbb{R}^n$: vecteur colonne $\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$ avec $x_1, x_2, \dots, x_n \in \mathbb{R}$.
- x^T : transposée du vecteur x , vecteur ligne (x_1, x_2, \dots, x_n) .
- $A \in \mathbb{R}^{m \times n}$ est la matrice $\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$.

De l'algèbre au programme linéaire

Définition 5 - Programme Linéaire

$$(PL) \begin{cases} \max c^T x = c_1 x_1 + c_1 x_1 + \dots + c_n x_n = \sum_{i=1}^n c_i x_i \\ a_{i1} x_1 + a_{i2} x_2 + \dots + a_{in} x_n \leq b_i, \quad i = 1, \dots, m \\ x_i \geq 0, \quad i \in I \subseteq \{1, \dots, m\} \end{cases}$$

où $x \in \mathbb{R}^n$ est le vecteur de variables inconnues.

- $f(x) = c^T x$: **fonction-objectif/de coût/économique.**
- $c \in \mathbb{R}^n$: **vecteur de coût.**
- A et b : collectent les informations des **contraintes.**

De l'algèbre au programme linéaire

Remarque 2 - Résolution du (PL)

- Généralement, A n'est pas carrée ($m \neq n$). Donc ?
- Habituellement, A a plus de colonnes que de lignes...Hum.
- Un grand choix de solutions maximisant $c^T x$ existe dans l'espace admissible M .

Remarque 3 - Maximisation et minimisation

L'opérateur de minimisation remplace parfois celui de maximisation. Le passage de l'un à l'autre requiert une simple manipulation : la maximisation de $c^T x$ devient la minimisation de $-c^T x$. Le résultat de la fonction objectif sera du coup $-f(x)$.

Exemple

Un agriculteur possède un nombre d'hectares (T), d'engrais (E) et d'insecticides (I), de maïs (x_1) ou de blé (x_2). Les cultures ont des quantités différentes d'engrais et d'insecticide (E_1, I_1, E_2, I_2), et fournissent un revenu différent (S_1, S_2). Modélisation de la situation :

Maximiser :	$S_1x_1 + S_2x_2$: fonction objectif
Soumis à :	$x_1 + x_2 \leq T$: limite du terrain
	$E_1x_1 + E_2x_2 \leq E$: limite pour l'engrais
	$I_1x_1 + I_2x_2 \leq I$: limite pour l'insecticide
	$x_1 \geq 0, x_2 \geq 0$: terrain positif

Généralités sur les fonctions de \mathbb{R}^2

- Limitation au cas 2D (pour y voir quelque chose...).
- Un demi-plan est défini par ?*
- Idée simple : construire la zone-solution en obtenant l'intersection de tous les demi-plans, solutions des inéquations.
- Exemple :

$$\begin{array}{ll}\max & 100x_1 + 250x_2 \\ \text{sujet à :} & x_1 + x_2 \leq 40, \\ & 40x_1 + 120x_2 \leq 2400, \\ & 6x_1 + 12x_2 \leq 312, \\ & x_1, x_2 \geq 0.\end{array}$$

Généralités sur les fonctions de \mathbb{R}^2

- Chaque contrainte : une équation de droite.
- Équation générale d'une droite dans \mathbb{R}^2 :

$$h(x, y) = ax + by + c = 0.$$

- Vecteur normal à la droite, noté n_h :

$$n_h = \begin{pmatrix} a \\ b \end{pmatrix}.$$

- Orienté dans la direction des valeurs croissantes de h .
- Dans l'autre sens : tourné vers les valeurs décroissantes de h .
- Utilité ? Savoir quel demi-plan il nous faut récupérer avec les inéquations.

Maintenant, l'espace de solutions !

- Construction par intersection de tous les *demi-espaces*, donc avec toutes les contraintes.
- Intersection de tous ces demi-espaces : un **polyèdre convexe**.

Définition 6 - Ensemble convexe

Un ensemble M est dit convexe si l'intégralité d'une ligne connectant deux points de M appartient à M .

Théorème 1 - Solution sur un polyèdre

*Soit f une fonction linéaire définie sur un polyèdre convexe borné. Alors la fonction f atteint sa valeur maximale en **au moins un des sommets** du polyèdre convexe.*

Programmation linéaire et simplexe

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente

- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal

Exemple de construction

- Travaillons avec les 3 contraintes du problème :

$$\begin{cases} g_1(x_1, x_2) = x_1 + x_2 \\ g_2(x_1, x_2) = 40x_1 + 120x_2 \\ g_3(x_1, x_2) = 6x_1 + 12x_2. \end{cases}$$

- Nature des contraintes ?*

- $n_{g_1} =$

Exemple de construction

- Travaillons avec les 3 contraintes du problème :

$$\begin{cases} g_1(x_1, x_2) = x_1 + x_2 \\ g_2(x_1, x_2) = 40x_1 + 120x_2 \\ g_3(x_1, x_2) = 6x_1 + 12x_2. \end{cases}$$

- Nature des contraintes ?*

- $n_{g_1} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

- n_{g_1} pointe vers valeurs croissantes de g_1 , ie $g(x_1, x_2) > 40$.

- Dans la direction opposée : tout point tel que $g(x_1, x_2) < 40$.

- Points dans l'espace réalisable qui nous intéresse ?*

Exemple de construction

- Même travail avec les autres contraintes, d'où 3 lignes au total :





Illustration des contraintes avec les 3 fonctions g_1 , g_2 et g_3 .

C'est bien beau, mais la solution ?

- On a toutes les solutions possibles ! Reste à trouver le meilleur des points !
- **Objectif** : $\max f(x_1, x_2) = 100x_1 + 250x_2$.
- Augmentation des valeurs de f dans la direction de la normale.
- La figure ci-dessous illustre deux déplacements de f :



Déplacements de la fonction-objectif selon la normale (négative ici !).


Et donc ???

- Sa normale est :

$$n_f(x_1, x_2) = \begin{pmatrix} 100 \\ 250 \end{pmatrix}.$$

- Puisque nous devons maximiser f :

- Déplacement de la droite de f dans la direction de n_f .
- Où sont les optimums ?*



Bref, résumons...

Étapes à suivre pour la résolution graphique :

- ➊ Tracer l'ensemble réalisable M_c à partir des contraintes.
- ➋ Tracer la fonction-objectif. Dans la pratique, on la fait initialement passer par $0_{\mathbb{R}^n}$ (par $(0, 0)^T$ dans \mathbb{R}^2).
- ➌ Déplacer la ligne de la fonction-objectif dans la direction définie par le vecteur c pour une maximisation.
- ➍ La solution optimale est l'intersection la plus extrême entre M_c et la ligne de la fonction-objectif.

Programmation linéaire et simplexe

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente

- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal

Bidouillons le système initial...

■ À partir du problème initial, on peut mettre le PL sous :

- ① Sa forme **canonique** : que des inéquations de même sens !

$$\sum_{j=1}^n a_{ij}x_j \geq b_i \Rightarrow \sum_{j=1}^n (-a_{ij})x_j \leq -b_i$$

$$\sum_{j=1}^n a_{ij}x_j = b_i \Rightarrow b_i \leq \sum_{j=1}^n a_{ij}x_j \leq b_i$$

$$\Rightarrow \sum_{j=1}^n a_{ij}x_j \leq b_i \quad \text{et} \quad \sum_{j=1}^n (-a_{ij})x_j \leq -b_i$$

- ② Sa forme **standard** : que des équations !

■ On utilisera des **variables d'écart**.

■ Elles compensent l'écart entre l'inégalité et l'égalité :

$$2x_1 - 3x_2 \leq 7 \Rightarrow 2x_1 - 3x_2 + e_1 = 7, \text{ avec } e_1 \geq 0.$$

Théorème fondamental

Théorème 2 - Théorème fondamental de prog. linéaire

Soit un (PLS), avec $M_s \neq \emptyset$. Alors :

- *Soit la fonction-objectif n'est pas bornée et il n'y a pas de solution optimale, soit le problème a une solution optimale et au moins un sommet de M_s est parmi ces solutions.*
- *Si M_s est borné, une solution optimale existe, et $x \in M_s$ est optimal si et seulement si il s'agit d'une combinaison convexe de sommets optimaux.*

Le simplexe en pratique

En principe :

- ① Avec les contraintes d'un (PLC), nous avons un ensemble convexe et la **solution optimale**, si elle existe, est **l'un des sommets de l'ensemble**.
- ② Pour la calculer, nous allons **partir d'un de ces sommets**.
- ③ Nous nous **déplaçons de sommet en sommet** le long des arêtes du polyèdre convexe jusqu'à trouver la solution optimale.

En pratique, du pivot de Gauss :

- ① Au départ, seules les variables d'écart sont prises en compte.
- ② On choisit la "variable entrante" qui contribue le plus.
- ③ On choisit la "variable sortante" qui contribue le moins.
- ④ On répète tant que l'un des coûts est positif.

Quelle sera la variable entrante ?

Remarque 4 - Premier critère de Dantzig : choix du pivot q

- *En principe, n'importe quelle composante de x (avec un coût positif).*
- *S'il n'existe pas de pivot q tel que $c_q > 0$, la solution optimale est trouvée et l'algorithme s'arrête.*
- *Dans le cas contraire, la stratégie la plus courante est de choisir le pivot q correspondant à **la composante la plus grande du vecteur de coûts**. Ce choix garantit la plus grande croissance de la fonction-objectif.*

Quelle sera la variable sortante ?

Remarque 5 - Second critère de Dantzig : choix du pivot p

Dans la pratique, grâce à l'application du pivot de Gauss, la stratégie pour choisir le pivot p (et donc la variable sortant de la base) est de prendre le minimum des rapports $\frac{b_i}{a_{iq}}$ pour $i = 1, \dots, m$, avec q la colonne de la variable entrante.

Exemple

Réolvons le problème suivant :

$$\begin{array}{ll}\max & f(x_1, x_2) = 6x_1 + 4x_2 \\ \text{Soumis à :} & 3x_1 + 9x_2 \leq 81 \\ & 4x_1 + 5x_2 \leq 55 \\ & 2x_1 + x_2 \leq 20 \\ & x_1, x_2 \geq 0\end{array}$$

Le problème est déjà écrit sous forme d'un (PLC). Sous sa forme standard, nous introduisons les variables d'écart afin d'obtenir des contraintes d'égalité :

$$\begin{array}{ll}\max & f(x_1, x_2) = 6x_1 + 4x_2 \\ \text{Soumis à :} & 3x_1 + 9x_2 + e_1 = 81 \\ & 4x_1 + 5x_2 + e_2 = 55 \\ & 2x_1 + x_2 + e_3 = 20 \\ & x_1, x_2, e_1, e_2, e_3 \geq 0\end{array}$$

Exemple

Itération 1

Variables de la base			Variables hors-base		
e_1	e_2	e_3	x_1	x_2	b
1	0	0	3	9	81
0	1	0	4	5	55
0	0	1	2	1	20
0	0	0	6	4	$f = 0$

Variable entrante : $x_e^{(1)} = \max(6, 4) = x_1$. Variable sortante : $\min\left(\frac{81}{3}, \frac{55}{4}, \frac{20}{2}\right) \Rightarrow x_s^{(1)} = e_3$.

Exemple

Itération 2

Variables de la base			Variables hors-base		
e_1	e_2	x_1	e_3	x_2	b
1	0	0	-3/2	15/2	51
0	1	0	-2	3	15
0	0	1	1/2	1/2	10
0	0	0	-3	1	$f = 60$

Variable entrante : $x_e^{(2)} = x_2$. Variable sortante : $\min \left(\frac{51}{15/2}, \frac{15}{3}, \frac{10}{1/2} \right) \Rightarrow x_s^{(2)} = e_2$.

- Pivot de Gauss : intersection de la colonne de x_1 et de la ligne e_3 .
- Élimination de tous les autres éléments de la colonne x_1 .
- Pourquoi Gauss ? La colonne de b est solution à chaque itération.

Exemple

Itération 3

Variables de la base			Variables hors-base		
e_1	x_2	x_1	e_3	e_2	b
1	0	0	$7/2$	$-5/2$	$27/2$
0	1	0	$-2/3$	$1/3$	5
0	0	1	$5/6$	$-1/6$	$15/2$
0	0	0	$-11/3$	$-1/3$	$f = 65$

Tous les coûts réduits sont négatifs. Optimum atteint avec $f = 65$.

Solution optimale :

$$\begin{cases} x_1^* &= 15/2 \\ x_2^* &= 5 \end{cases}$$

Optimum : $f(x_1^*, x_2^*) = 6x_1^* + 4x_2^* = 6 * 15/2 + 4 * 5 = 65$.

Algorithmes de descente

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente


- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal


Vocabulaire



Exemple de minima et maxima locaux et globaux de
 $f(x) = 3e^{-x^2} + e^{-(x-3)^2}$.

- Différences avec les cas précédemment présentés ?
- **Par la suite : optimisation numérique sans contraintes !**

Vocabulaire



Infinité de minima et maxima locaux, sans extréma globaux avec $f(x) = x\cos(x)$.

Définition 7 - Ensemble convexe

Soit $E \subset \mathbb{R}^n$. L'ensemble E est convexe ssi :

$$\forall (x, y) \in E^2, \forall \lambda \in]0, 1[, \lambda x + (1 - \lambda)y \in E.$$

En d'autres termes : si x et y sont deux éléments de E , le segment qui relie x à y est inclus dans E .

Définition 8 - Fonction convexe

Soit $E \subset \mathbb{R}^n$ et $f: E \rightarrow \mathbb{R}$. La fonction f est convexe ssi :

$$\forall (x, y) \in E^2, \forall \lambda \in]0, 1[, f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Optimisation num. sans contraintes

Théorème 3 - Condition suffisante d'optimalité globale

Soit $E \subset \mathbb{R}^n$ un convexe et $f: E \rightarrow \mathbb{R}$ une fonctionnelle. Soit x^ un point minimum local de f . Alors :*

- *Si f est convexe, alors x^* est un minimum global de f .*
- *Si f est strictement convexe, alors x^* est l'unique point minimum global de f .*

Mais le monde n'est pas uniquement convexe... :(

Optimisation num. sans contraintes

Objectif 1

Comprendre les méthodes numériques pour la recherche de points $x \in \mathbb{R}^n$ qui réalisent le minimum d'une fonction $f: \mathbb{R}^n \rightarrow \mathbb{R}$.

Théorème 4 - CN d'optimalité locale d'ordre 1

Soit $f: \mathbb{R}^n \rightarrow \mathbb{R}$ une application différentiable. Si $x^* \in \mathbb{R}^n$ réalise un minimum local (resp. maximum local) de f , alors :

$$\nabla f(x^*) = 0.$$

Et en français ? Les zéros du gradient (de la dérivée) sont tous les points candidats en tant qu'extrema locaux potentiels. On les appelle **points critiques** ou **points stationnaires**. Parmi eux : minima locaux, maxima locaux, **points selle**.

Optimisation num. sans contraintes

Définition 9 - Fonction différentiable et dérivable

- Une fonction $f: I \rightarrow \mathbb{R}$ est dérivable en $a \in I$ si le taux d'accroissement $\frac{f(x)-f(a)}{x-a}$ admet une limite quand x tend vers a . La limite est alors notée $f'(a)$.
- La notion de fonction différentiable est la généralisation aux fonctions de plusieurs variables.

Définition 10 - Point critique

Soit $f: \mathbb{R}^n \rightarrow \mathbb{R}$ une application différentiable. Tout point $x \in \mathbb{R}^n$ vérifiant :

$$\nabla f(x) = 0$$

est appelé point **critique** ou point **stationnaire** de f .

Algorithmes de descente

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente

- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal

Objectif 2

À partir d'un point x_0 arbitraire, un algorithme de descente va chercher à générer une suite d'itérés $(x_k)_{k \in \mathbb{N}}$ telle que :

$$\forall k \in \mathbb{N}, \quad f(x_{k+1}) \leq f(x_k).$$

Qu'est-ce-que cette "descente" ?

Direction de descente

- Il y a beaucoup de directions de descente...
- Mais celle qui nous intéressera est celle où la pente est la plus forte : la direction du gradient !

Définition 11 - Direction de plus forte descente

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction différentiable et $x \in \mathbb{R}^n$. La direction de plus forte descente est donnée par :

$$d^* = -\nabla f(x).$$

Algorithmes de descente

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente

- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal

Algorithme de descente

Principe :

- 1 $k = 0$.
- 2 Tant que le test de convergence n'est pas satisfait (cf. plus loin),

2.1 Trouver une direction de descente d_k telle que

$$\nabla f(x_k)^T d_k < 0$$

2.2 Choisir un pas $s_k > 0$ à faire dans cette direction, tel que :

$$f(x_k + s_k d_k) < f(x_k).$$

2.3 Mettre à jour : $x_{k+1} = x_k + s_k d_k$.

2.4 $k = k + 1$.

- 3 Retourner x_k .

Critères d'arrêt

■ Pour l'arrêt de l'algorithme :

- ❶ Critère d'optimalité : $\|\nabla f(x_k)\| < \varepsilon$.
- ❷ Stagnation de la solution : $\|x_{k+1} - x_k\| < \varepsilon \|x_k\|$.
- ❸ Stagnation de la valeur : $\|f(x_{k+1}) - f(x_k)\| < \varepsilon \|f(x_k)\|$.
- ❹ Nombre d'itérations dépassant un seuil fixé : $k < IterMax$.

■ En pratique : (1) ou [(2) et (3)] ou (4).

■ Notions importantes mises de côté :

- ❶ Convergence locale ? Globale ?
- ❷ Vitesse de convergence :

$$\lim_{k \rightarrow +\infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^p} = \tau, \text{ avec } \tau \geq 0.$$

- Si $p = 1$ et $\tau \in [0, 1] \Rightarrow$ convergence linéaire.
- Si $p = 1$ et $\tau = 0 \Rightarrow$ convergence superlinéaire.
- Si $p > 1$ et $\tau \geq 0 \Rightarrow$ convergence d'ordre p .

Algorithmes de descente

Introduction

Programmation linéaire et simplexe

- Vocabulaire et principe

- Résolution graphique

- Résolution par tableaux

Algorithmes de descente

- Vocabulaire et principe

- Les algorithmes de descente

- Schéma général d'un algorithme de descente

- Descente de gradient à pas fixe et optimal

Descente à pas fixe et optimal

Principe :


- On admet que la direction de plus profonde descente normalisée est :

$$d_k = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|}.$$

- Il faut maintenant le "pas" le long de cette direction :
 - Choix d'un pas fixe : naïf, mais ça marche... ou pas :)
 - Choix d'un pas optimal $s_k > 0$, solution de

$$\min_{s>0} f(x_k + sd_k).$$

Descente à pas fixe et optimal



Comparaison entre pas fixe et pas optimal pour une fonction donnée.